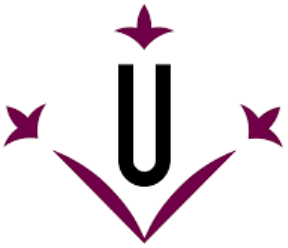

Universitat de Lleida

Exercicis d'ARA

Bayesian Inference

Realitzat per:
Oriol Alàs Cercós, Marta Albets Mitjaneta, Sergi Simón Balcells

Data de lliurament:
8 de Juny de 2020

Universitat de Lleida
Escola Politècnica Superior
Grau en Enginyeria Informàtica
Aprenentatge i Raonament Automàtic

Professorat:
Ramón Béjar

Índex

Índex de taules

Índex de figures

1 Introducció

2 Parseig de dades

El parseig de les dades es realitza en dos fitxers continguts en `src`:

- `__main__.py` conte la funció `main` i funcions de parseig dels arguments passats per la línia de comandes.
- `weka.py` conte funcions auxiliars per a categoritzar les dades i per a crear els texts que amb format arff per a weka.

2.1 Linia de comandes

Per a parsejar les dades passades per la línia d'ordres, donat que el projecte semblava requerir bastants arguments, s'ha utilitzat el mòdul estàndard d'`argparser`. Aquest ens permetia posar arguments opcionals per a ser utilitzats en el parseig. Així doncs, els diferents arguments que es poden passar són:

- `input-file, train-file, test-file` són els arguments requerits per l'enunciat de la pràctica. Input file és l'únic fitxer que ha d'estar creat amb anterioritat i ha de contindre un csv amb els valors que es volen parsejar.
- `pri, rev, lat, lon`: són diferents paràmetres que permeten canviar el nombre de particions en els arguments *price, reviews, latitude i longitude* respectivament. Per a canviar el valor, s'ha d'especificar un enter després del parametre, per exemple: `python3 -m src ... -pri 3`.
  Aquests paràmetres han servit per a provar diferents valors en com partir les dades pel weka. En la següent secció s'explicarà de quina manera s'ha realitzat i el perquè d'aquesta.
- `cpri, crev, clat, clon`: Dins de les maneres que es poden dividir en classificacions diferents dades contínues, hi ha dues formes que destaquen: fer la divisió per centils o realitzar-la amb rangs de valors de la mateixa mida. La diferència de realitzar-la per quantils és que tots els rangs tindran el mateix nombre de valors[1]. Però, dividir-la així pot deixar en un mateix rang valors forans i valors normals, és a dir, si es dividís en dos grups la llista [2, 3, 4, 2000], 4 i 2000 aniran al mateix grup quan aparentment tenen poc sentit que ho siguin. Amb aquest paràmetre permetem en executar l'script, canviar la funció de tall d'un tall per rangs amb la mateixa mida als creats a partir de quartils.
- `name`: permet canviar el nom de la relació amb què es guarda. S'ha d'especificar en el paràmetre: `python3 -m src ... -n notmydataset`.
- `seed`: permet canviar la llavor en la qual s'agafen els valors per a fer els dos datasets (train i test). Si no s'especifica, s'agafa el valor per defecte dels últims 5 dígits d'un dels autors de la pràctica, com s'especificava a l'enunciat.

Dins d'aquest codi s'utilitzen dos funcions:

- `ArgumentParser`: constructor de la classe. Ens permet crear un parser on l'hi podem atribuir una descripció que s'utilitzarà amb el paràmetre *help* opcional.
- `add_argument`: ens permet afegir un argument. Si comença amb el caràcter '-', serà opcional, i es podrà especificar un nom verbós, com per exemple `-n` i `--name` realitzen la mateixa funció. Aquest mètode accepta diferents tipus de paràmetres per a canviar el seu comportament. A continuació s'expliquen els que s'han utilitzat en aquesta:
  - `metavar`: especifica una variable que s'utilitzarà per a mostrar el missatge d'ajuda per a paràmetres no opcionals.
  - `type`: ens permet especificar com s'ha de parsejar els valors per a poder ser utilitzats en el codi. En el nostre cas, només s'utilitza `str` i `int`.

[1] Realment, si la divisió per quartils no és exacta, un conjunt podria tenir menys valors, és a dir, si es divideix entre quatre conjunts un conjunt de 13 valors, llavors un d'aquests inevitablement tindrà un valor de més.

- `help`: proporciona un text d'ajuda quan es realitza la comanda `--help`.
- `dest`: variable amb la que serà guardada en el parseig.
- `action`: especifica una acció per a realitzar. Només s'ha utilitzat per a guardar una constant *'store_const'*.
- `const`: especificar la constant a guarda quan s'utilitza `'store_const'`. Amb conjunció amb el valor `default` i amb `action`, ens permet canviar la funció a utilitzar pel tall.

2.2 Weka i pandas

Per a realitzar la funció de parseig s'ha utilitzat pandas. Per a fer-ho, s'ha utilitzat la funció `read_csv`. A partir d'aquí, la manipulació de dades s'ha realitzat amb conjunció amb numpy. Així doncs, per a realitzar la discretització de les dades contínues, s'ha utilitzat les funcions[2] `qcut` i `cut`. Aquestes dues funcions accepten els mateixos paràmetres, perquè el canvi es pot realitzar fluidament. A més a més per a fer el canvi d'una columna continua, es pot realitzar amb: `df[column_name] = cut_func(df[column], number_divisions, labels=False)`. *Labels* permet canviar el nom en el qual es categoritzen, passant dels rangs a noms donats com a llista. Per facilitar el parseig, s'ha passat el valor `False`, que canvia simplement numera les instàncies.

A més a més, s'ha realitzat la funció de `parse_weka`, que retorna una `str` representant la informació en format arff. S'ha retornat el valor en comptes de guardar-lo directament en el fitxer per separar la lògica d'on i que es guarda. La funció en si és una agrupació de `join` de les files i columnes per les diferents línies. La divisió dels datasets es realitza en la mateixa funció per assegurar que els dos sempre tindran el mateix nom a la relació i els atributs.

2.3 Partició de les dades

Per tal de passar els atributs que tenen valors reals a valors discrets, hem utilitzat la llibreria `pandas`, que ens permet llegir el `csv` d'una manera molt còmode i partir-lo de diferents maneres. Les funcions que s'han incorporat al nostre script de parseig són:

- `cut`. Divideix el dataset en diferents intervals utilitzant el rang de valors.
- `qcut`. Divideix el dataset mitjançant quantiles, és a dir, tots els intervals tindran el mateix nombre de dades.

A més a més, es va pensar en un primer moment, utilitzar `KMeans` per tal d'agrupar la longitud i la latitud en un sol atribut. No obstant això, els atributs no han de tenir correlació directa. Weka ja ho realitzarà per nosaltres mitjançant models probabilístics. Per tant, s'ha declinat utilitzar aquesta opció.

Per tal d'arribar a la conclusió de quin mètode era el millor per tal de categoritzar els atributs, s'ha utilitzat la llibreria `matplotlib` per tal de visualitzar les dades de manera gràfica. S'ha realitzat un gràfic[3] per cada atribut a categoritzar sobre l'*overall_satisfaction* i després havent-lo categoritzat. Aquest procediment s'ha realitzar bastants cops fins trobar una partició que fos representativa.

El mètode de cada atribut realitzat es pot veure a la Taula 1. Com es pot observar, el millor mètode per tal de preservar el comportament del continu el millor possible és utilitzant `cut`.

Atribut	Mètode	Num. Divisions
price	cut	15
reviews	cut	10
latitude	cut	20
longitude	cut	20

Taula 1: Mètodes de partició utilitzats segons cada atribut

[2] L'explicacació de les funcions es pot trobar a la secció 2.3.
[3] Els gràfics poden trobar a la secció A de l'apèndix.

3 Models

En aquest apartat, podem veure els valors de la puntuació log(UPSM) i el percentatge d'error de classificació obtinguts en els diferents models de cadascuna de les classes de models.

3.1 Models de la classe 1

1. **log(UPSM):** -92608.96126554035 **Error de classificació:** 48.4167 %
2. **log(UPSM):** -92139.67866809308 **Error de classificació:** 48.4167 %
3. **log(UPSM):** -92388.27489566772 **Error de classificació:** 48.4167 %
4. **log(UPSM):** -92227.05224681877 **Error de classificació:** 48.4484 %
5. **log(UPSM):** -92066.4712487785 **Error de classificació:** 48.4167 %
6. **log(UPSM):** -92302.15263672064 **Error de classificació:** 48.4167 %
7. **log(UPSM):** -92180.71383973274 **Error de classificació:** 48.4167 %
8. **log(UPSM):** -92586.42609497187 **Error de classificació:** 48.4167 %
9. **log(UPSM):** -92245.67223271335 **Error de classificació:** 48.4167 %
10. **log(UPSM):** -93188.71009303001 **Error de classificació:** 48.4167 %

Per a poder seleccionar el millor model dels anteriors, ens hem de fixar sobretot en quin d'ells ens classifica correctament un major nombre d'instàncies i, per tant, vaga la redundància, quin model té el menor percentatge d'error de classificació.
Com podem observar, tots els models tenen el mateix percentatge d'error excepte un, el qual podem descartar directament, ja que és més alt que la resta. Entre els altres models, no ens sorpèn que el percentatge no variï, ja que observant les dades que se'ns donaven inicialment i després de separar-les en els conjunts d'aprenentatge i testing, veiem una tendència d'un 50% de casos en els quals el valor del overall_satisfaction és de 4.5.

Per tant, veient totes les dades, podem arribar a la conclusió que ens podriem trobar en una situació d'"empat". Una manera de resoldre'l, i la que utilitzarem, serà comparar els valros del log(UPSM) de cada model.
Per concloure, considerarem que, el millor model d'entre els que tenen el mateix i millor percentatge en aquesta classe, serà aquell que tingui un UPSM socre més elevat, es a dir, el model que el seu log(UPSM) sigui més baix. Per tant, considerarem com a millor model de la classe 1, el classificat amb el nombre 5, del qual es pot observar la seva representació gràfica a la Figura 1.

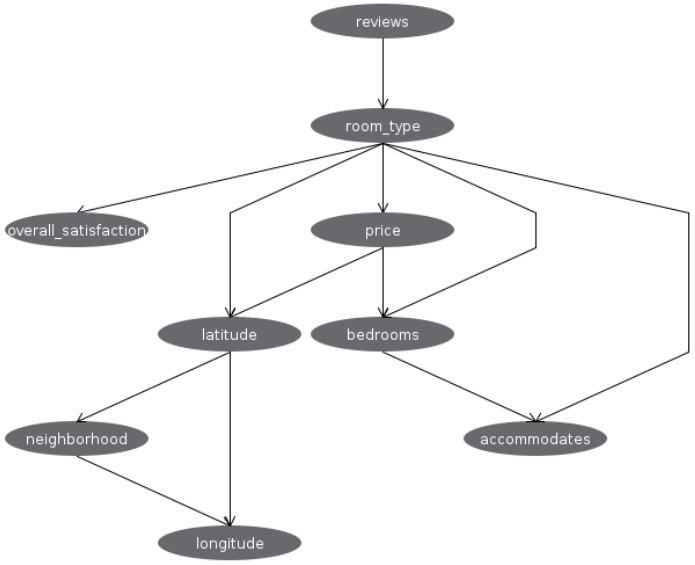

Figura 1: Millor model de la classe 1

3.2 Model de la classe 2

1. **log(UPSM):** -117515.15847723951 **Error de classificació:** 48.4484 %

En el cas de la segona classe, només hi trobem un model possible, per tant, serà aquest ek qual considerarem com a millor. El fet que només n'hi hagi un de possible és degut a que aquest model és el corresponent a la xarxa bayesiana naive, tenint com a variable de classe overall_satisfaction, el qual és un model únic.
A la figura 2 es pot veure la representació gràfica d'aquest model.

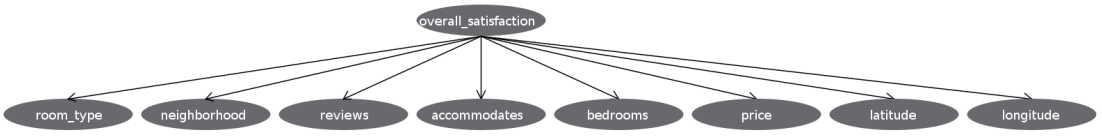

Figura 2: Millor model de la classe 2

3.3 Models de la classe 3

1. **log(UPSM):** -96800.35169816265 **Error de classificació:** 48.3534 %
2. **log(UPSM):** -95829.88423245584 **Error de classificació:** 48.86 %
3. **log(UPSM):** -95565.62218051209 **Error de classificació:** 48.8284 %
4. **log(UPSM):** -95859.94046082163 **Error de classificació:** 48.4167 %

5. **log(UPSM):** -97231.01625115846 **Error de classificació:** 48.7334 %
6. **log(UPSM):** -96894.65682950999 **Error de classificació:** 48.3217 %
7. **log(UPSM):** -95822.6410503832 **Error de classificació:** 48.67 %
8. **log(UPSM):** -97094.31982431604 **Error de classificació:** 48.1951 %
9. **log(UPSM):** -95604.5241813889 **Error de classificació:** 48.575 %
10. **log(UPSM):** -96108.4925816474 **Error de classificació:** 48.3534 %

Per tal de poder escollir el millor model d'aquesta classe, s'ha fet de la mateixa manera que en la classe 1. Tot i això, en aquest cas sí que hem pogut veure més diversitat de percentatges d'error en els diferents models. I, per aquest motiu, no ha estat necessàri comparar les valors del UPSM.

Els percentatges son bastant semblant entre si, ja que el fet d'enceratr algunes variables més que un altre model, no implica un gran canvi en el percentateg d'encerts, degut a la gran quantitat d'instàncies que tenim en el test. Malgrat tot, hi ha hagut un model que ha encertat algunes instàncies més que la resta. Per tant, considerem com a millor model de la classe 3, el classificat amb el nombre 8, del qual es pot observar la seva representació gràfica a la Figura 3.

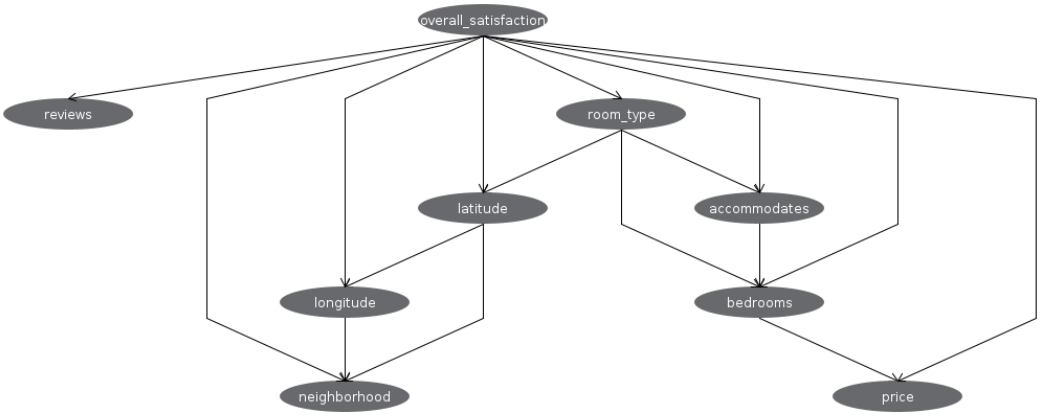

Figura 3: Millor model de la classe 3

A Gràfics

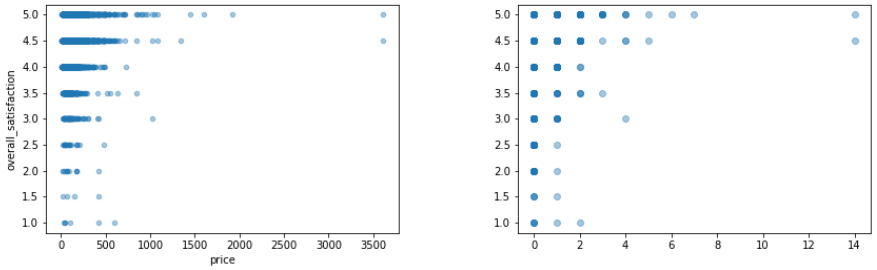

(a) (b)

Figura 4: Scatter de l'atribut price (a) continu (b) discret

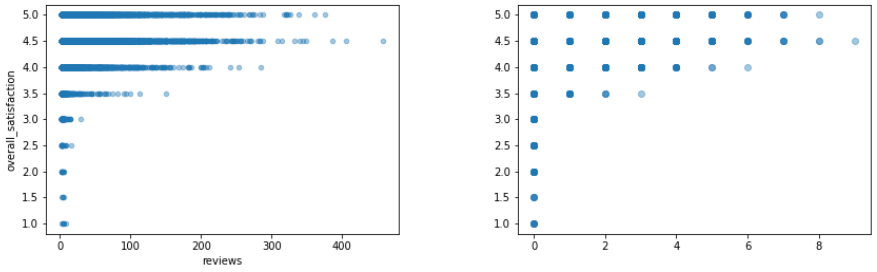

(a) (b)

Figura 5: Scatter de l'atribut reviews (a) continu (b) discret

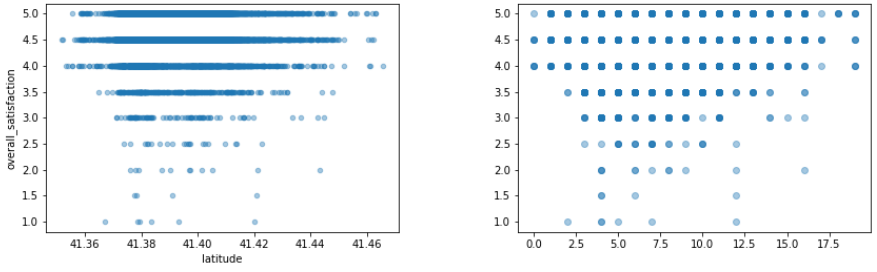

(a) (b)

Figura 6: Scatter de l'atribut latitude (a) continu (b) discret

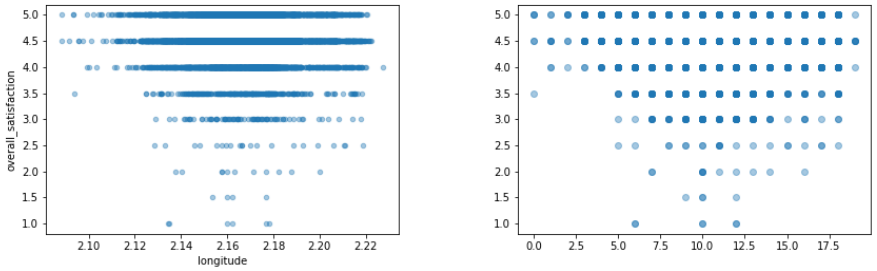

(a) (b)

Figura 7: Scatter de l'atribut longitude (a) continu (b) discret