



Universitat de Lleida

Exercicis d'ARA

Bayesian Inference

Realitzat per:

Oriol Alàs Cercós, Marta Albets Mitjaneta, Sergi Simón Balcells

Data de lliurament:

8 de Juny de 2020

Universitat de Lleida
Escola Politècnica Superior
Grau en Enginyeria Informàtica
Aprenentatge i Raonament Automàtic

Professorat:
Ramón Béjar

Índex

1	Introducció	2
2	Parseig de dades	2
2.1	Linia de comandes	2
2.2	Weka i pandas	3
2.3	Partició de les dades	3
3	Models	3

Índex de figures

Índex de taules

1 Introducció

2 Parseig de dades

El parseig de les dades es realitza en dos fitxers continguts en `src`:

- `__main__.py` conte la funció `main` i funcions de parseig dels arguments passats per la línia de comandes.
- `weka.py` conte funcions auxiliars per a categoritzar les dades i per a crear els texts que amb format `arff` per a `weka`.

2.1 Línia de comandes

Per a parsejar les dades passades per la línia d'ordres, donat que el projecte semblava requerir bastants arguments, s'ha utilitzat el mòdul estàndard d'`argparser`. Aquest ens permetia posar arguments opcionals per a ser utilitzats en el parseig. Així doncs, els diferents arguments que es poden passar són:

- `input-file`, `train-file`, `test-file` són els arguments requerits per l'enunciat de la pràctica. Input file és l'únic fitxer que ha d'estar creat amb anterioritat i ha de contindre un `csv` amb els valors que es volen parsejar.
- `pri`, `rev`, `lat`, `lon`: són diferents paràmetres que permeten canviar el nombre de particions en els arguments *price*, *reviews*, *latitude* i *longitude* respectivament. Per a canviar el valor, s'ha d'especificar un enter després del paràmetre, per exemple: `python3 -m src ... -pri 3`. Aquests paràmetres han servit per a provar diferents valors en com partir les dades pel `weka`. En la següent secció s'explicarà de quina manera s'ha realitzat i el perquè d'aquesta.
- `cpri`, `crev`, `clat`, `clon`: Dins de les maneres que es poden dividir en classificacions diferents dades contínues, hi ha dues formes que destaquen: fer la divisió per centils o realitzar-la amb rangs de valors de la mateixa mida. La diferència de realitzar-la per quantils és que tots els rangs tindran el mateix nombre de valors¹. Però, dividir-la així pot deixar en un mateix rang valors forans i valors normals, és a dir, si es divideix en dos grups la llista `[2, 3, 4, 2000]`, 4 i 2000 aniran al mateix grup quan aparentment tenen poc sentit que ho siguin. Amb aquest paràmetre permetem en executar l'script, canviar la funció de tall d'un tall per rangs amb la mateixa mida als creats a partir de quantils.
- `name`: permet canviar el nom de la relació amb què es guarda. S'ha d'especificar en el paràmetre: `python3 -m src ... -n notmydataset`.
- `seed`: permet canviar la llavor en la qual s'agafen els valors per a fer els dos datasets (train i test). Si no s'especifica, s'agafa el valor per defecte dels últims 5 dígits d'un dels autors de la pràctica, com s'especificava a l'enunciat.

Dins d'aquest codi s'utilitzen dos funcions:

- `ArgumentParser`: constructor de la classe. Ens permet crear un parser on l'hi podem atribuir una descripció que s'utilitzarà amb el paràmetre `help` opcional.
- `add_argument`: ens permet afegir un argument. Si comença amb el caràcter `'-`, serà opcional, i es podrà especificar un nom verbós, com per exemple `-n` i `--name` realitzen la mateixa funció. Aquest mètode accepta diferents tipus de paràmetres per a canviar el seu comportament. A continuació s'expliquen els que s'han utilitzat en aquesta:
 - `metavar`: especifica una variable que s'utilitzarà per a mostrar el missatge d'ajuda per a paràmetres no opcionals.
 - `type`: ens permet especificar com s'ha de parsejar els valors per a poder ser utilitzats en el codi. En el nostre cas, només s'utilitza `str` i `int`.

¹Realment, si la divisió per quantils no és exacta, un conjunt podria tenir menys valors, és a dir, si es divideix entre quatre conjunts un conjunt de 13 valors, llavors un d'aquests inevitablement tindrà un valor de més.

- **help**: proporciona un text d’ajuda quan es realitza la comanda `--help`.
- **dest**: variable amb la que serà guardada en el parseig.
- **action**: especifica una acció per a realitzar. Només s’ha utilitzat per a guardar una constant `'store_const'`.
- **const**: especificar la constant a guarda quan s'utilitza `'store_const'`. Amb conjunció amb el valor `default` i amb `action`, ens permet canviar la funció a utilitzar pel tall.

2.2 Weka i pandas

Per a realitzar la funció de parseig s’ha utilitzat `pandas`. Per a fer-ho, s’ha utilitzat la funció `read_csv`. A partir d’aquí, la manipulació de dades s’ha realitzat amb conjunció amb `numpy`. Així doncs, per a realitzar la discretització de les dades contínues, s’ha utilitzat les funcions `qcut` i `cut`, la primera fent-ho amb quartils. Aquestes dues funcions accepten els mateixos paràmetres, perquè el canvi es pot realitzar fluidament. A més a més per a fer el canvi d’una columna continua, es pot realitzar amb: `df[column_name] = cut_func(df[column], number_divisions, labels=False)`. `Labels` permet canviar el nom en el qual es categoritzen, passant dels rangs a noms donats com a llista. Per facilitar el parseig, s’ha passat el valor `False`, que canvia simplement numera les instàncies.

A més a més, s’ha realitzat la funció de `parse_weka`, que retorna una `str` representant la informació d’arff. S’ha retornat el valor en comptes de guardar-lo directament en el fitxer per separar la lògica d’on i que es guarda. La funció en si és una agrupació de `join` de les files i columnes per les diferents línies. La divisió dels datasets es realitza en la mateixa funció per assegurar que els dos sempre tindran el mateix nom a la relació i els atributs.

2.3 Partició de les dades

3 Models